

Архиватор на базе Алгоритма Хаффмана

Тайманов Балкан Мередович

Группа: «2025.Б73-мм»

Кафедра: кафедра Системного программирования

Научный руководитель: Литвинов Юрий Викторович

Номер семестра практики: 2

1. Введение

Алгоритм Хаффмана — один из алгоритмов сжатия данных без потерь, предложенный Дэвидом Хаффманом в 1952 году. Идея алгоритма состоит в том, что символы встречающиеся чаще, получают более короткий код, а редкие символы более длинный. Благодаря этому общий размер закодированных данных уменьшается. Важным свойством алгоритма является префиксность кодов: ни один код не является началом другого.

2. Постановка задачи

Целью работы является реализация консольного архиватора файлов на основе алгоритма Хаффмана.

В ходе работы необходимо решить следующие задачи:

1. Реализация необходимых структур данных: бинарное дерево и минимальная куча.
2. Реализация алгоритма сжатия файлов на основе алгоритма Хаффмана.
3. Реализация алгоритма разжатия файлов.
4. Написание модульных и интеграционных тестов для проверки корректности работы.
5. Проведение экспериментов по измерению степени сжатия и скорости работы на файлах различных типов и размеров.

Результатом работы является готовый консольный инструмент, позволяющий сжимать и разжимать произвольные файлы.

3. Описание предлагаемого решения

Для реализации архиватора был выбран язык программирования C. Данный выбор обусловлен желанием реализовать все компоненты с нуля, без использования высокоуровневых абстракций, а также возможностью работы напрямую с памятью и битовыми операциями, что особенно важно при побитовом кодировании данных.

Алгоритм сжатия

Сжатие файла выполняется в несколько этапов. На первом этапе файл читается побайтово и подсчитываются частоты встречаемости каждого байта. Результатом является массив из 256 элементов, где индекс это значение байта, а значение — его частота.

На втором этапе из полученных частот строится минимальная куча. Использование кучи обеспечивает эффективное построение дерева Хаффмана за $O(n \log n)$. Каждый элемент кучи — узел дерева, содержащий символ и его частоту.

На третьем этапе строится дерево Хаффмана. На каждой итерации из кучи извлекаются два узла с минимальными частотами, из них создаётся новый родительский узел с частотой равной сумме частот детей, который добавляется обратно в кучу. Процесс повторяется до тех пор, пока в куче не останется один узел — корень дерева Хаффмана.

После построения дерева генерируется таблица префиксных кодов обходом дерева в глубину (DFS). При переходе к левому ребёнку к текущему коду добавляется бит 0, при переходе к правому — бит 1. Когда алгоритм доходит до листа, накопленная последовательность битов становится кодом соответствующего символа.

Затем входной файл читается повторно, и каждый байт заменяется его кодом из таблицы. Биты накапливаются в буфере размером один байт. Как только буфер заполняется, он записывается в выходной файл и обнуляется. В начало сжатого файла записывается таблица частот — массив из 256 значений типа `int`, необходимых для восстановления дерева при разжатии.

Алгоритм разжатия

Разжатие начинается с чтения заголовка сжатого файла — таблицы частот. Таблица частот была выбрана для хранения в заголовке намеренно: из неё можно восстановить дерево Хаффмана, а из дерева — таблицу кодов. Это более компактно чем хранить саму таблицу кодов.

По таблице частот восстанавливается куча и дерево Хаффмана. Затем оставшиеся данные файла читаются побайтово. Каждый байт обрабатывается побитово: бит 0 означает переход к левому ребёнку дерева, бит 1 — к правому. Как только алгоритм доходит до листа, соответствующий символ записывается в выходной файл, и обход начинается заново с корня. Процесс продолжается до тех пор, пока не будет восстановлено исходное количество символов.

Инструменты и технологии

Реализация осуществлялась с использованием следующих технологий: язык C (стандарт C99), система сборки CMake, система автоматической сборки и тестирования GitHub Actions. Для контроля качества кода используются AddressSanitizer и Valgrind. Поскольку эти два инструмента конфликтуют между собой, в CI настроены два отдельных job: первый выполняет сборку с AddressSanitizer и запускает тесты, второй собирает проект без санитайзеров и запускает Valgrind. Также используется статический анализатор `cppcheck`.

Структура проекта

Проект разделён на независимые модули, каждый из которых отвечает за свою часть алгоритма:

- tree — реализация бинарного дерева. Содержит структуру узла и функции создания и освобождения дерева.
- heap — реализация минимальной кучи. Содержит функции добавления узла, извлечения минимального элемента и освобождения памяти.
- huffman_tree — основная логика алгоритма. Содержит подсчёт частот, построение кучи из частот, построение дерева Хаффмана и создание таблицы кодов.
- encode — модуль сжатия файла.
- decode — модуль разжатия файла.
- error — вывод сообщений об ошибках.

4. Эксперименты

Тестирование

Для проверки корректности работы архиватора были написаны модульные и интеграционные тесты с использованием библиотеки assert.

Модульные тесты проверяют работоспособность каждой функции алгоритма в отдельности. Для каждого теста создавались временные входные данные, которые передавались на вход функции, после чего результат сравнивался с ожидаемым. Были написаны тесты для следующих модулей: бинарное дерево, минимальная куча, подсчёт частот, построение дерева Хаффмана и генерация таблицы кодов.

Интеграционный тест проверяет работоспособность программы целиком: создаётся временный текстовый файл, выполняется сжатие и разжатие, после чего результат побайтово сравнивается с оригиналом.

Замеры производительности

Для исследования эффективности алгоритма были проведены эксперименты на файлах различных типов и размеров. Каждый замер выполнялся 10 раз, после чего вычислялось математическое ожидание и среднеквадратическое отклонение.

Для экспериментов были выбраны следующие файлы:

- Большой текстовый файл (3.3 МБ) — для проверки эффективности на типичных данных
- Маленький текстовый файл (14 байт) — для проверки поведения на маленьких файлах
- JPEG изображение (1.3 МБ) — уже сжатый формат
- ZIP архив (1.3 МБ) — уже сжатый формат
- Пустой файл — файл без данных

Файл	Тип	Оригинал	Сжатый	Степень сжатия
bigTXT.txt	Текст (большой)	3.3 МБ	1.7 МБ	50%
smallTXT.txt	Текст (маленький)	14 Б	1.1 МБ	увеличение
photo.jpg	JPEG	1.3 МБ	1.3 МБ	без изменений
photo.zip	ZIP	1.3 МБ	1.3 МБ	без изменений
empty.txt	Пустой файл	0 Б	—	ошибка

Таблица 1: Результаты экспериментов




Рис. 1: Степень сжатия, время сжатия и время разжатия

Файл	М encode (с)	СКО encode	М decode (с)	СКО decode
bigTXT.txt	0.429	0.009	0.392	0.006
smallTXT.txt	0.018	0.002	0.019	0.002
photo.jpg	0.248	0.008	0.300	0.016
photo.zip	0.252	0.011	0.282	0.006
empty.txt	0.019	0.003	—	—

Таблица 2: Время работы архиватора

Выводы

Алгоритм Хаффмана показал высокую эффективность на большом текстовом файле — степень сжатия составила около 50%. Это ожидаемый результат, так как в текстовых файлах одни символы встречаются намного чаще других, что позволяет алгоритму хорошо их кодировать.

На уже сжатых форматах (JPEG, ZIP) алгоритм не эффективен — размер файла почти не изменился. Это объясняется тем, что такие форматы уже используют сжатие, и распределение байтов в них близко к равномерному — алгоритму просто нечего оптимизировать.

На маленьком текстовом файле размер после сжатия увеличился. Это происходит из-за того, что в начало сжатого файла записывается таблица частот размером 1024 байта, что значительно больше самого файла.

Пустой файл обрабатывается корректно — программа выводит сообщение об ошибке и завершает работу.

5. Заключение

В ходе выполнения работы получены следующие результаты:

- Реализован консольный архиватор файлов на основе алгоритма Хаффмана на языке C, поддерживающий сжатие и разжатие произвольных файлов.
- Реализованы необходимые структуры данных: бинарное дерево и минимальная куча.
- Написаны модульные тесты для каждого модуля и интеграционный тест, проверяющий корректность сжатия и разжатия.
- Настроена автоматическая проверка кода через GitHub Actions: сборка, тесты, линтер и Valgrind.
- Проведены эксперименты на файлах различных типов и размеров с вычислением математического ожидания и среднеквадратического отклонения.

Репозиторий: <https://github.com/taymanov-bn/Huffman-archiver>